

Module 02 Data Engineering for AI

وحدة 02 هندسة البيانات للذكاء الاصطناعي

7 Modules + Lab + Glossary

Interactive Learning Journey

وحدات المقرر Course Modules

V06 أساسيات البيانات Data Fundamentals

V07 المستودعات والبحيرات ومعمارية Warehouses, Data Lakes & Lakehouse


V08 هندسة الخصائص ومخازنها Feature Engineering & Feature Stores

V09 قواعد البيانات المتجهية RAG + التطبيقي Vector Databases + Applied RAG

V10 تصنيف البيانات على نطاق واسع Labeling at Scale

V11 حوكمة البيانات وسلسلة العهدة والفهرسة Data Governance, Lineage & Cataloging

V12 أساسيات MLOps + تمهيد للمختبر MLOps Fundamentals + Lab Introduction



V06 Data Fundamentals

Why Data is Important

أهمية البيانات


THE PROBLEM



“Without data, you are just another person with an opinion.” - William Deming

- Leads to confusion
- Wasted resources
- Bad decisions

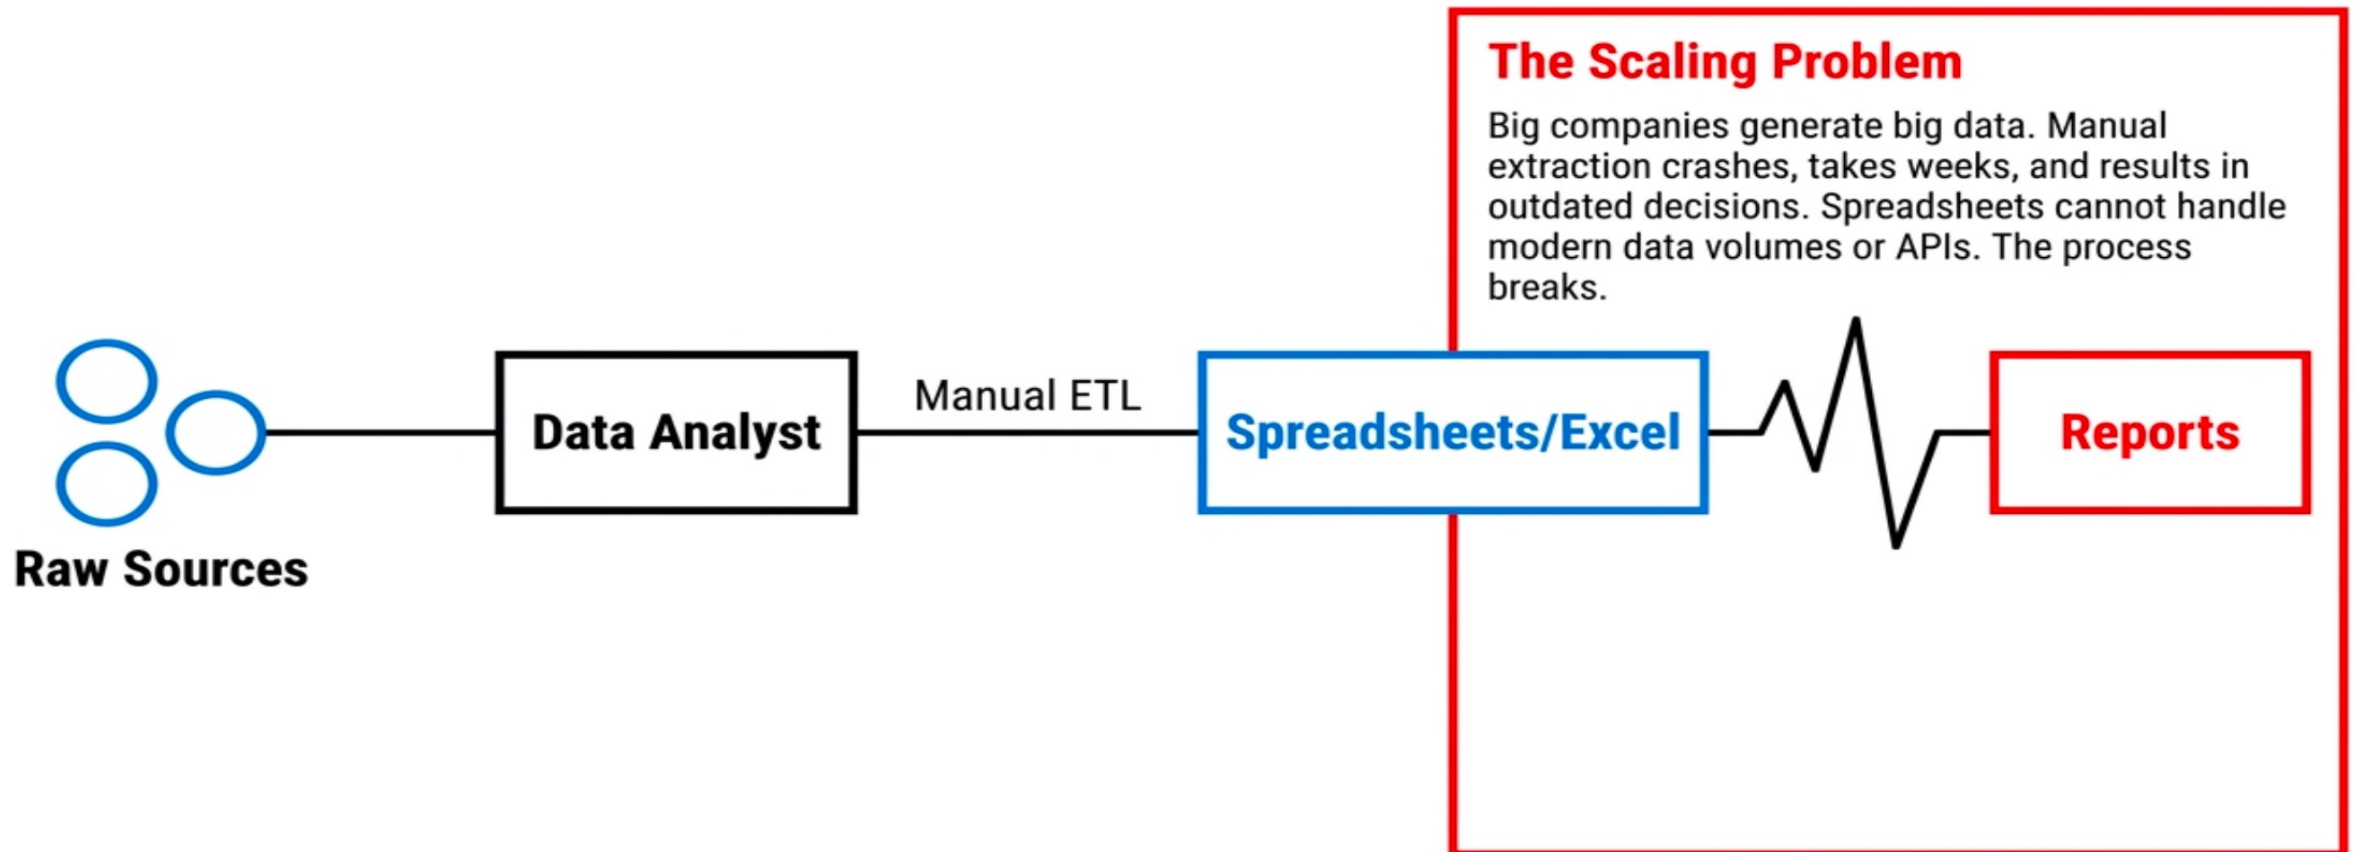
THE SOLUTION



Replaces guesswork with facts
for fast, smart decisions.

Big Data

البيانات الضخمة



Types of Data Platforms

أنواع قواعد و منصات البيانات

Storage Architectures

Data Warehouse

Structured, relational, optimized for BI. (Subject-oriented, integrated, non-volatile).

Data Lake

Flexible, stores structured + unstructured (images/logs). Risk: Can become a data swamp.

Lakehouse

The modern hybrid. Flexibility of a lake + structure of a warehouse.

Data Mesh

Decentralized. Departments build and share their own data products.

Database Types Matrix

Relational (SQL)


Tables/Rows/Columns.
(e.g., SQL Server, PostgreSQL).

NoSQL Variants

- Key-Value (Dictionaries)
- Column-based (Heavy searching)
- Graph (Relationships/Nodes)
- Document (JSON pages)

Unified Data/AI Platform

تقنيات معالجة منصة البيانات الموحدة و الذكاء الاصطناعي



Unified Data/AI Platform

تقنيات معالجة منصة البيانات الموحدة و الذكاء الاصطناعي

Data Analysis and Segmentation

- جمع البيانات الأولية ، من خلال معالجة الأنشطة ، و التعرف على البيانات ، وتحديد جودة البيانات ، واكتشاف السمات الداخلية للبيانات مع اكتشاف المجموعة الفرعية المثيرة للاهتمام لتشكيل فرضية المعلومات الضمنية. إنشاء منظومة البيانات الموحدة من البيانات غير المعالجة و تشمل اختيار الجداول والسجلات والخواص ، بالإضافة إلى تحويل وتنظيف البيانات لأدوات النمذجة.

Predictive Forecasting Models

- استخدام تقنيات الذكاء الاصطناعي في اختيار تقنيات نماذج مختلفة وتطبيقها ، وتعديل معلمات النموذج إلى أفضل القيم. بشكل عام ، بما يساعد علي إيجاد حلول فعالة لمشكلة التنقيب في البيانات .
- تحليل السلاسل الزمنية و التنبؤ بالقيمة المستقبلية للسلسلة باستخدام المتوسطات المتحركة لتحليل السلاسل الزمنية إلى مكونات موسمية واتجاهية وغير منتظمة. التعامل مع المكونات الموسمية المضافة أو المضاعفة.

Anomaly & Fraud Detection

- اعداد القواعد المعرفية في النظم الخبيرة هي مزيج من الخصائص والقوانين ونتائج الخبرة المكتسبة والمعلومات الدقيقة والادراك
- استخدام برامج الذكاء الاصطناعي للوصول إلى استنباط الظواهر و الأنماط الغير الطبيعية في البيانات و احتمال مخالفتها للقوانين و المحددات من خلال المسارات داخل قاعدة المعرفة

Decision Optimization & What-If-Scenarios

- حل المشاكل الجديدة، والتخطيط، واتخاذ القرارات والقدرة على التعامل مع المشاكل غير المتوقعة واستخلاص النتائج باستخدام المعلومات المخزنة
- محاكاة النتائج المستقبلية و الوصول الي افضل البدائل لتعظيم العائد من المشروع


AI and Data Teams

فرق عمل الذكاء الاصطناعي و هندسة البيانات

Role	Core Question	Focus	Primary Output	System Activity
Data Analyst	What happened?	Past/Present	Visual Reports (PowerBI/Tableau)	Prototyping / Discovery
BI Developer	How do we scale this?	Past/Present	24/7 Interactive Dashboards	Production / Engineering
Data Scientist	What will happen next?	Future	Predictive Models (Python)	Prototyping / Discovery
ML Engineer	How do we automate this?	Future	Deployed AI Systems / APIs	Production / Engineering
Data Architect & Engineer	How does data flow?	Foundation	Pipelines & Data Warehouses	Blueprint & Engine Room

AI and Data Teams

فرق عمل الذكاء الاصطناعي و هندسة البيانات



طيف البيانات والتنسيقات Data Spectrum & Formats

مهيكلية
Structured

شبه مهيكلية
Semi-structured

غير مهيكلية
Unstructured

جداول
Tables
CSV Databases

سجلات مرنة
Flexible records
JSON Avro

نصوص وصور وصوت
Text, images, audio
PDF JPG MP3

اختر التنسيق حسب الاستخدام تبادل بسيط ← تحليلات سريعة ← محتوى غني
Choose the format for the job simple exchange ← fast analytics ← rich content

مسارات ETL & ELT

ETL التحويل قبل التحميل؛

ELT التحميل أولاً ثم التحويل داخل المنصة المستهدفة.

ETL transform before loading; ELT load first, transform inside the target platform.

ELT هو النمط السائد في بيئات Lakehouse الحديثة.

ELT is the dominant pattern in modern lakehouse environments.

V07 Warehouses, Data Lakes & Lakehouse

أجندة العرض Agenda

V07 المستودعات والبحيرات ومعمارية Lakehouse, Data Lakes & Lakehouse


- المستودع مقابل البحيرة Warehouse vs Lake
- معمارية Lakehouse
- منتجات البيانات وعقودها Data Products & Contracts
- متى تختار كل نموذج؟ When to Choose Which

المستودع مقابل البحيرة Warehouse vs Lake Decision Map


Data Warehouse



Data Lake



Data Lakehouse



مقارنة أنماط المعالجة Processing Patterns

المعمارية المتدرّجة Medallion Lakehouse

Bronze خام → **Silver** منقّى → **Gold** الأنسب للتحليلات وخطوط؛ إدارة مركزية؛ **AI ML RAG** جاهز للتحليل؛

Medallion Lakehouse raw Bronze → cleansed Silver → analytics-ready Gold; central ownership; best for analytics and AI ML RAG pipelines.

مستودع البيانات Datawarehouse

ETL → **Staging** → الأعمال؛ الأنسب للتقارير وذكاء الأعمال؛ حوكمة مركزية؛ أسواق البيانات؛ المستودع.

Data warehouse ETL ELT → staging → warehouse → data marts; central governance; best for reporting and BI.

شبكة البيانات Data Mesh

وكتالوج موحد؛ الأنسب للمؤسسات الكبيرة **SLA**، ملكية لامركزية بالمجالات؛ منتجات بيانات بعقود مخطط، أمان

Data mesh decentralized domain ownership; data products with contracts schema, security, SLA and a unified catalog; best for large organizations.

خريطة قرار المستودع مقابل البحيرة Warehouse vs Lake Decision Map

مستودع البيانات
Data Warehouse

مخطط عند الكتابة
Schema on write

بيانات منظمة **SQL** +
Curated data + SQL

تقارير وذكاء أعمال
Reporting and BI

بحيرة البيانات
Data Lake

مخطط عند القراءة
Schema on read

كل التنسيقات
Any format

استكشاف و**AI ML**
Exploration and AI ML

Lakehouse = مرونة البحيرة + موثوقية
المستودع


**Lakehouse = lake flexibility + warehouse
reliability**

جدول المقارنة Medallion المستودع Data Mesh

المعيار	Medallion	المستودع	Data Mesh
الفكرة	طبقات Bronze→Silver→Gold	Staging→Warehouse →Marts	منتجات بالمجالات
المالك	هندسة مركزية	BI فرق	فرق المجالات
الأنسب	AI RAG تحليلات و	BI تقارير	مؤسسات كبيرة
الحوكمة	جودة بين الطبقات	مركزية	موحدة + عقود

Modern Data Platform Architecture (Medalion)

المعمارية المتدرجة لمنصات البيانات الحديثة




المعمارية المتدرّجة Medallion Layers

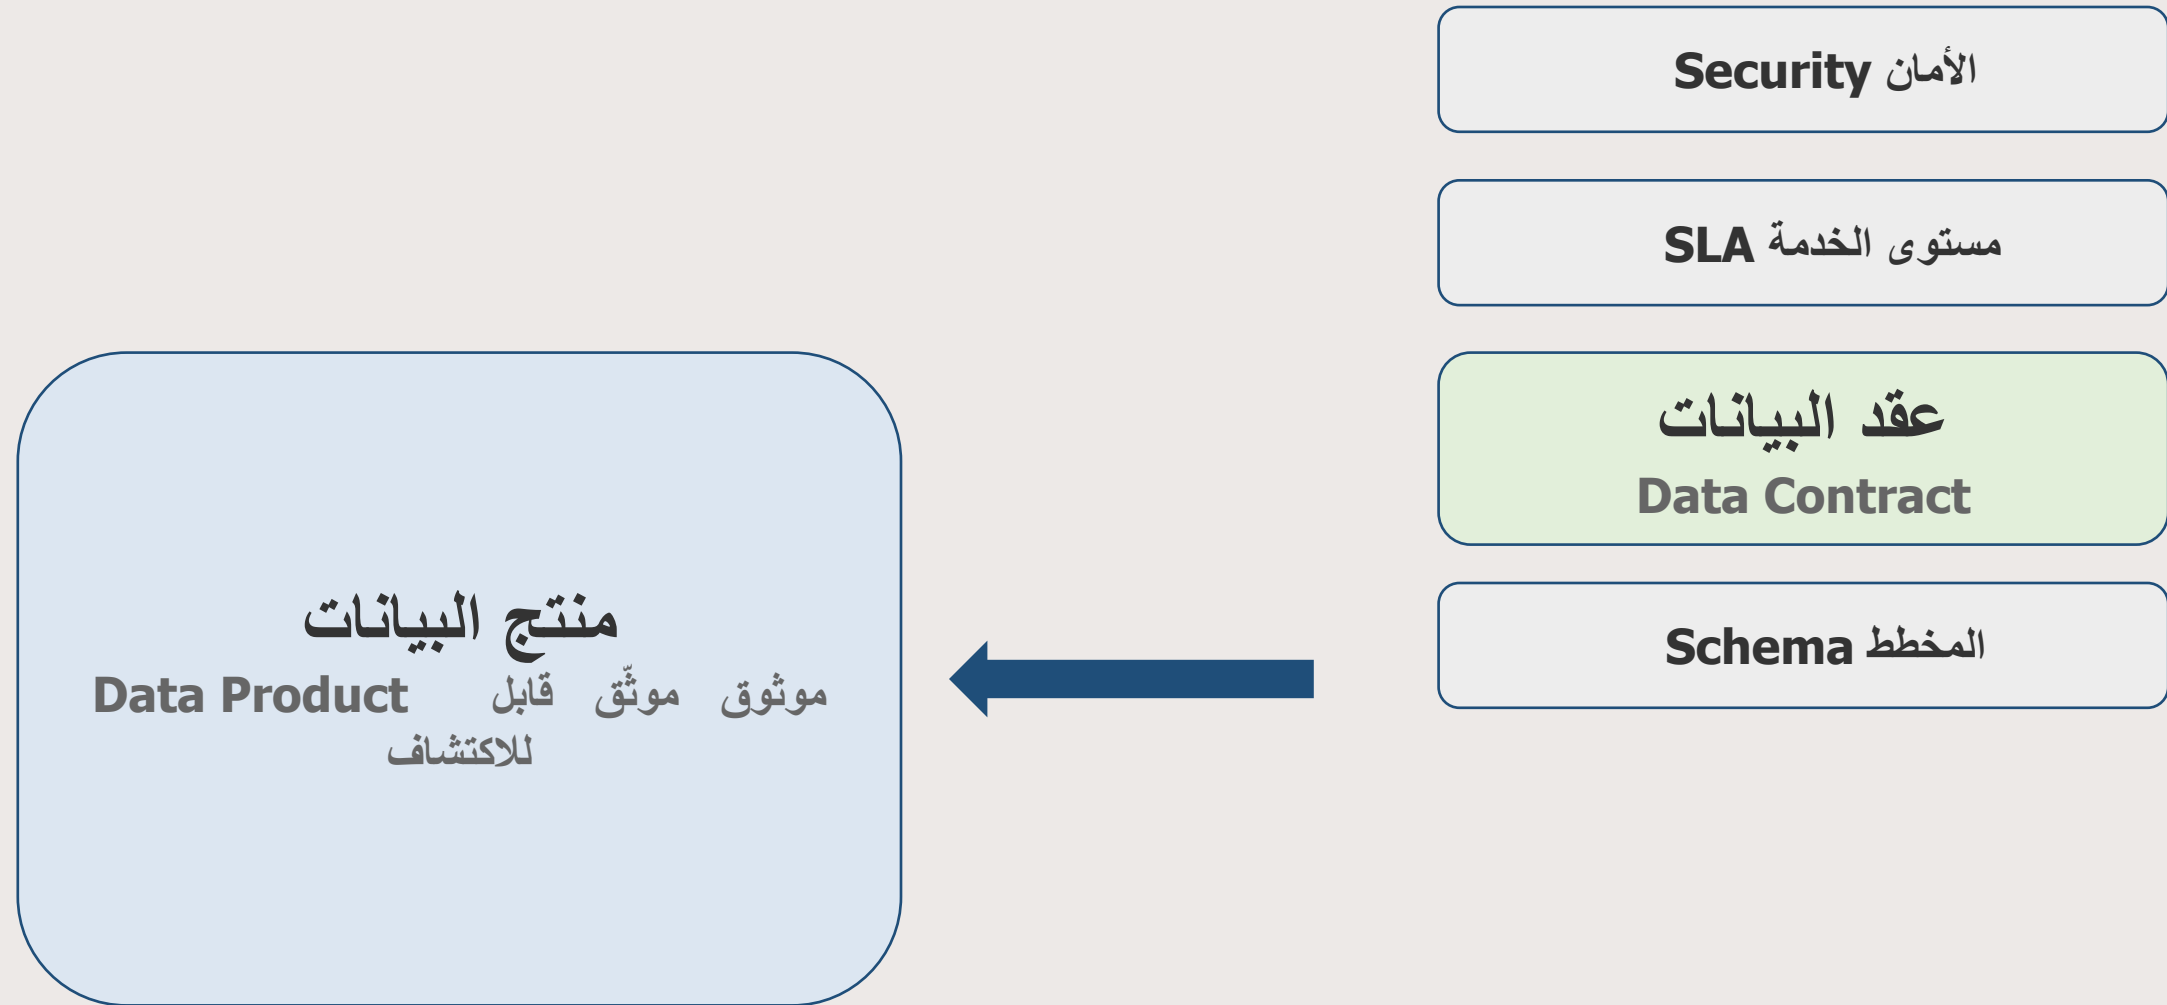


Unified Data/AI Platform

تقنيات معالجة منصة البيانات الموحدة و الذكاء الاصطناعي



منتج البيانات وعقد البيانات Data Product & Contract



متى تختار كل نموذج؟ Decision Matrix

السبب	الاختيار	الحالة
مرونة + حوكمة طبقية	Medallion Lakehouse	فريق مركزي + تحليلات
SQL سريع + مخطط ثابت	Warehouse	تقارير صارمة
ملكية لامركزية + عقود	Data Mesh	فرق مستقلة كبيرة

Three Data Patterns أنماط معالجة البيانات الثلاثة

المعمارية المتدرّجة
Medallion

مستودع البيانات
Data Warehouse

شبكة البيانات
Data Mesh

فريق مركزي تحليلات و **AI ML**
RAG

فرق **BI** تقارير وذكاء أعمال

فرق المجالات مؤسسات كبيرة

V08 Feature Engineering & Feature Stores


أجندة العرض Agenda

V08 هندسة الخصائص ومخازنها Feature Engineering & Feature Stores

- هندسة الخصائص Feature Engineering
- مخازن الخصائص Feature Stores
- اتساق Offline Online Consistency
- الربط بالتطبيقات الوكيله Agentic Applications


Feature Engineering Importance

أهمية هندسة الخصائص للبيانات




Measures answer 'How Much?' or 'How Many?'. Dimensions answer 'Who, What, Where?' and are used to group the data.

من البيانات الخام إلى الخصائص Raw Data to Features




معمارية مخزن الخصائص Feature Store Architecture




Design Patterns of Data Platforms

أنماط تصميم منصات البيانات



Star Schema: Simple, fast for reporting (PowerBI), denormalized.



Snowflake Schema: Complex, highly normalized, saves storage but requires heavy SQL joins.

Feature Engineering is a MUST for AI

أهمية هندسة خصائص البيانات للذكاء الاصطناعي

Descriptive Analytics

- **Question:** What happened? (e.g., How many customers left?)
- **Tool:** SQL, BI Dashboards.
- **Role:** Data Analyst.

Predictive Analytics

- **Question:** What will happen? (e.g., Which customers will leave next month?)
- **Process:** Exploratory Data Analysis (EDA) -> Feature Engineering (Deriving new data columns) -> Train/Test Data Split -> Apply Algorithm -> Deploy Model.
- **Role:** Data Scientist & ML Engineer.

Feature Engineering is the most critical step. AI cannot find insights if the raw data isn't transformed into smart, derived features.

الربط بالتطبيقات الوكيلية Agentic Applications


الوكلاء يحتاجون ميزات لحظية متسقة لقرارات التخصيص والمخاطر والتوجيه.

Agents need consistent real-time features for personalization, risk, and routing.


مخزن الخصائص هو «مصدر الحقيقة» للميزات أمام أي وكيل ذكي.

The feature store is the single source of truth behind any agent.


RAG



Agentic RAG



من LLM إلى الأنظمة الوكيلية LLM to Agentic AI




V09 Vector Databases + Applied RAG

أجندة العرض Agenda

V09 قواعد البيانات المتجهية RAG + التطبيق Vector Databases + Applied RAG


- قواعد البيانات المتجهية Vector Databases
- الفهرسة استراتيجيات التقسيم Indexing Chunking
- الاسترجاع Retrieval
- التوليد Generation
- التقييم + التحسين Evaluation + Optimization
- الأخطاء الشائعة Common Pitfalls

خط مسارات RAG Pipeline



End-to-End RAG Pipeline

المسار المتكامل لنظام الاسترجاع التوليدي المعزز



استراتيجيات تقسيم النصوص Chunking Strategies

ثابت الحجم Fixed-size	أبسطها يقطع الجُمْل
دلالي Semantic	تماسك أفضل حساس للعتبة
تكراري ★ Recursive	الموصى به افتراضياً
بحسب البنية Structure-based	عناوين وأقسام يُدمج مع التكراري
بالنموذج اللغوي LLM-based	الأدق الأعلى حسابياً

الاسترجاع Retrieval

بحث هجين كثيف + Dense متناثر BM25 يغطي المعنى والكلمات المفتاحية معًا.

Hybrid search dense + sparse BM25 covers meaning and keywords.

إعادة ترتيب Cross-encoder وتحويل الاستعلام Multi-Query يرفعان دقة النتائج.


Cross-encoder reranking and multi-query transformation improve precision.

التوليد Generation

موجّه مقيد بالمصادر المسترجعة Grounded Prompting مع الاستشهاد «أجب فقط من السياق المرفق.»»

Grounded prompting strictly on retrieved sources with citations 'answer only from the provided context'.

نمط الإجابة المؤرّضة Grounded Answer Pattern



التقييم + التحسين Evaluation + Optimization

مثلث RAG


- **Faithfulness** الوفاء
- **Answer Relevancy** ملائمة الإجابة
- **Context Precision** ، دقة السياق

RAG triad faithfulness, answer relevancy, context precision measured with RAGAS.

التحسين تخزين دلالي مؤقت، توجيه الطلبات بين النماذج، ومراقبة مستمرة.

Optimization semantic caching, model routing, continuous monitoring.

RAG RAG Evaluation Triad مثلث تقييم





Common Pitfalls الأخطاء الشائعة

تقسيم يكسر الجداول أو الأكواد؛ إهمال إعادة الترتيب فيضيع الأكثر ملاءمة.

Chunking that breaks tables code; skipping reranking loses the most relevant hits.

غياب تقييم الوفاء فيسمح بالهلوسة؛ استرجاع أعلى-ك دون حد أدنى للدرجة.

No faithfulness evaluation allows hallucination; top-k without a score floor.

 Indexing Chunking Strategy (Recursive), Embedding Model (Domain-aligned), Vector Index (HNSW).	 Retrieval Hybrid Search (Dense+Sparse), Reranking (Cross-encoder), Query Transformation (Multi-Query).	 Generation Grounded Prompting (Strict Instructions), Source Citations.
	 Evaluation The RAG Triad (Faithfulness, Answer Relevancy, Context Precision).	
	 Optimization Semantic Caching, Model Routing, Continuous Monitoring.	

V10 Labeling at Scale

أجندة العرض Agenda

V10 تصنيف البيانات على نطاق واسع Labeling at Scale

- فهم أهمية جودة التسميات **Labels** لنجاح النماذج الخاضعة للإشراف
- التعرف على سير عمل التوسيم البشري **Human-in-the-Loop** في عصر **LLM**
- فهم آليات ضبط الجودة مثل اتفاق المُعلّقين والتحقق الآلي
- التعرف على التعلّم النشط و **RLHF** وأثرهما على تقليل تكلفة التوسيم

اهمية جودة التسميات Importance of Data Labeling

1

قمامة تدخل، قمامة تخرج

80% من إخفاقات مشاريع الذكاء الاصطناعي تُعزى إلى ضعف جودة البيانات، لا ضعف النموذج

2

أنواع التوسيم

تصنيف نصوص، صناديق إحاطة للصور، تجزئة دلالية، وتصنيف تفضيلات المحادثات RLHF

3

التحدي

التوسيم اليدوي البحث بطيء ومكلف، ولا يتناسب مع أحجام بيانات نماذج اليوم

ضمان الجودة وتقليل التكلفة

1

اتفاق المُعلِّقین

قياس مدى اتساق قرارات فرق
التوسيم المختلفة (Inter-
Annotator Agreement)

2

المراجعة المتعددة


تمرير نفس العينة على أكثر من
معلّق للعينات الحرجة، مع تدقيق
آلي مساعد

3

التعلّم النشط

إعطاء الأولوية للعينات الأكثر
إفادة للنموذج (الأكثر غموضًا أو
تنوعًا) بدل توسيم كل شيء

حلقة جودة التصنيف Label Quality Loop



LLM-assisted Labeling LLM التصنيف بمساعدة

نموذج لغوي يقترح التصنيفات مبدئيًا لتسريع العملية وخفض التكلفة.


An LLM pre-labels examples to speed up the process and cut cost.

التحقق البشري **Human-in-the-loop** إلزامي قبل القبول، مع قياس اتفاق النموذج مع البشر.

Human-in-the-loop validation is mandatory before acceptance, measuring human–model agreement.

LLM-assisted Labeling Workflow

سير عمل التصنيف بمساعدة LLM



اتجاهات 2026: من التوسيم اليدوي إلى المنظومة الهجينة

1

تسبيق آلي بنماذج لغوية

نماذج مثل GPT و Claude تُنتج تسميات أولية بكلفة هامشية منخفضة (LLM Pre-labeling)

2

بيانات اصطناعية للحالات النادرة

توليد أمثلة تركيبية تسد فجوات الندرة دون المساس بخصوصية البيانات الحقيقية

3

البشر و RLHF للحالات الحرجة

المُعلّقون البشر يُخصّصون للحالات الغامضة والحسّاسة، وتصنيف التفضيلات لتحسين نماذج الدردشة

أشهر الأدوات المستخدمة

1

Label Studio

منصة توسيم مفتوحة المصدر
ومجانية عند الاستضافة الذاتية؛
أصبحت خيارًا شائعًا لبناء بيانات
تصنيف تفضيلات RLHF

2

Roboflow

منصة رؤية حاسوبية متكاملة
(توسيم + تدريب + نشر)
بمساعدة توسيم تلقائي (Auto
Label)

3

Scale AI

منصة توسيم مؤسسية بفرق
بشرية مُدارة، ومرجع رئيسي
لبينات RLHF لدى مختبرات
الذكاء الاصطناعي الكبرى

أهمية جودة تصنيف البيانات

✓ بيانات التدريب عالية الجودة لا تقل أهمية عن جودة النموذج نفسه

✓ التوسيم في 2026 منظومة هجينة: نماذج لغوية للتسبيق، بيانات اصطناعية للندرة، وبشر للحالات الحرجة

✓ التعلّم النشط و RLHF يقلّان تكلفة التوسيم دون التضحية بالجودة

✓ اختيار الأداة يعتمد على نوع البيانات، الميزانية، والحاجة لفريق بشري مُدار

V11 Data Governance, Lineage & Cataloging

أجندة العرض Agenda

Data Governance, Lineage & Cataloging V11 حوكمة البيانات وسلسلة العهدة والفهرسة

- الحوكمة والفهرسة **Governance & Cataloging**
- المعمارية المرجعية للذكاء التوليدي **GenAI Reference Architecture**


الحوكمة والفهرسة Governance & Cataloging

سلسلة العهدة Lineage تتبع أصل البيانات وتحولاتها؛ الفهرسة تجعلها قابلة للاكتشاف.


Lineage traces data origin and transformations; cataloging makes it discoverable.

أدوات. Apache Atlas، Collibra، DataHub، OpenMetadata.

Tools Apache Atlas, Collibra, DataHub, OpenMetadata



خريطة سلسلة العهدة Data Lineage Map



لكل خطوة مالك + وقت + سياسة + أثر التغيير
For every step owner + time + policy + change impact

أ. بوابة منصة **GenAI** نافذة موحدة بكتالوج حلول ومحفظة **POC → MVP → PROD** موثقة.

A. Portal unified pane of glass with a solution catalog and documented **POC → MVP → PROD** portfolio.

ب. الأتمتة والامتثال خطوط **CI/CD** ببوابات تحكم آلية وموافقات مرحلية وفق **DevSecOps**.

B. Automation & compliance **CI/CD** with automated control gates and stage-gate approvals **DevSecOps** .

ج. الخدمات المشتركة بوابة **AI** موحدة، مكتبة موجّهات، خدمة التغذية الراجعة، قاعدة تدقيق **LLM**، حواجز حماية **Guardrails**.

C. Shared services unified AI gateway, prompt library, feedback service, LLM audit database, guardrails.

د. الحوكمة والمراقبة أمن البيانات، الذكاء المسؤول تدقيق التحيز والهلوسة ، وإدارة التكاليف **FinOps**.

D. Governance & monitoring data security, responsible AI bias hallucination audits , FinOps.

المعمارية المرجعية للذكاء التوليدي GenAI Reference Architecture

أ. بوابة منصة GenAI

A. Platform Portal POC → MVP → PROD

ب. الأتمتة والامتثال

B. Automation & Compliance CI CD gates

ج. الخدمات المشتركة


C. Shared Services Gateway, Prompts, Audit, Guardrails

د. الحوكمة والمراقبة

D. Governance & Monitoring Responsible AI, FinOps

Generative AI and LLM Fine-Tuning using YOUR Data


الذكاء الاصطناعي التوليدي وتحسين نماذج التعلم الآلي باستخدام بياناتك



MCP: Model Context Protocol

بروتوكول سياق النموذج

(e.g., Email Agent,
Database Agent)




V12 MLOps Fundamentals + Lab Introduction

أجندة العرض Agenda

V12 أساسيات MLOps + تمهيد للمختبر MLOps Fundamentals + Lab Introduction

- MLOps والأدوات MLOps & Tools
- تمهيد المفاهيم Concept Distinctions
- RAG الوكيل Agentic RAG
- التكلفة والأداء عمليًا Practical Cost & Performance
- تمهيد للمختبر Lab Introduction



MLOps Lifecycle دورة حياة

MLflow لتتبع التجارب والنماذج **Kubeflow** ، لأتمتة الخطوط **DVC** ، لإصدارات البيانات.

MLflow for tracking, Kubeflow for pipeline automation, DVC for data versioning.



سجل الإصدارات والقياسات في كل مرحلة ثم أعد التعلم من الإنتاج
Record versions and metrics at every stage then learn again from production

تميز المفاهيم Concept Distinctions


LLM يرمز النص ويتنبأ بالرموز التالية. الذكاء التوليدي يولد محتوى جديدًا نص صورة صوت.

LLM predicts next tokens. Generative AI generates new content text image audio.

الوكلاء يكشفون النية ويستدعون الأدوات. الأنظمة الوكيلية تخطط ذاتي وتنفيذ متعدد الخطوات مع تقييم للنتائج.

Agents detect intent and call tools. Agentic AI self-directed multi-step planning with outcome evaluation.

من LLM إلى الأنظمة الوكيلية From LLM to Agentic AI



التكلفة والأداء عمليًا Practical Cost & Performance

التضمين Embedding أقل تكلفة بمرتبة كاملة من التوليد Generation الاسترجاع أرخص من التوليد.

Embedding costs an order of magnitude less than generation retrieval is cheaper than generation.


التخزين الدلالي المؤقت يخفض الكمون والتكلفة؛ توجيه الطلبات يرسل المهام البسيطة لنماذج أصغر أرخص.

Semantic caching cuts latency and cost; routing sends easy tasks to smaller, cheaper models.

قاعدة FinOps قس التكلفة لكل طلب per-request قبل التوسع.

FinOps rule measure per-request cost before scaling.

التكلفة عمليًا التضمين مقابل التوليد Cost Embedding vs Generation



معمارية مختبر Lab Architecture

Gold ChromaDB HNSW cosine ← تنظيف + تقسيم 50 50 Silver ← خام SQLite Bronze etl_pipeline.py ETL خط

ETL etl_pipeline.py Bronze raw SQLite → Silver clean + 500 50 chunk → Gold ChromaDB HNSW cosine, batches of 10

golden كاش دلالي 0.92 ← تقييم ← OpenRouter free حد 0.2 ← توليد مؤرّض top-k=5 استرجاع كثيف rag_api.py 8000 الخلفية

Backend rag_api.py 8000 dense top-k=5 ≥ 0.2 → grounded OpenRouter free → semantic cache 0.92 → golden eval

مع حذف المجموعة Chroma تبويبات ثنائية رفع مستندات استعلام تقييم حول تُعيد استخدام نفس عميل 5 streamlit_ui.py 8501 الواجهة

Frontend streamlit_ui.py 8501 5 bilingual tabs upload docs query eval about same Chroma client, drop & recreate

للمفتاح .env + golden_dataset.json + chroma_db gold_chunks + silver_chunks bronze_docs lab.db المخازن

Stores lab.db bronze_docs silver_chunks + chroma_db gold_chunks + golden_dataset.json + .env for keys

Running the Lab تشغيل مختبر

```
cd Lab + source .venv bin activate
```

```
OMP_NUM_THREADS=1 MKL_NUM_THREADS=1 TOKENIZERS_PARALLELISM=false python -u etl_pipeline.py
```

```
./run_ui.sh → http localhost 8501
```

```
uvicorn rag_api app --reload → http localhost 8000 docs
```

```
python rag_api.py evaluate
```


L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

Docs

7

Chunks

784

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

RAG Pipeline — Visual Explanation

Explore each step of the Retrieval-Augmented Generation pipeline interactively.

Select a view:

- ETL Overview
- Embedding Space
- RAG Pipeline
- Full Flow

ETL Layers: Bronze → Silver → Gold

- Bronze** (📄): Raw documents stored unmodified in SQLite
- Silver** (🧹): Documents cleaned, normalized, recursively chunked (500 chars, 50 overlap)
- Gold** (🏆): Chunks embedded and indexed in ChromaDB with HNSW (cosine distance)

📄 Bronze

(Raw Documents)

🧹 Silver

(Cleaned & Chunked)

🏆 Gold

(Indexed Embeddings)

Documents

7

-

Chunks

0

Indexed Vectors

784

ETL Process Details

📄 Bronze Layer

What happens:

- Read TXT, MD, CSV, PDF files

🧹 Silver Layer

What happens:

- Remove exact duplicates

🏆 Gold Layer

What happens:

- Convert chunks to embeddings

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

📁 Docs

7

📊 Chunks

784

🛠️ Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🎓 RAG Pipeline — Visual Explanation

Explore each step of the Retrieval-Augmented Generation pipeline interactively.


Select a view:

- ☐ ETL Overview ☒ Embedding Space ☐ RAG Pipeline ☐ Full Flow

📊 Chunk Embedding Visualization

See how chunks are positioned in embedding space. Similar chunks cluster together.

📊 Chunk Embedding Space (PCA Projection)



📌 784 chunks visualized in 2D space using PCA dimensionality reduction

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

 Docs

 Chunks

7

784

📦 Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🎓 RAG Pipeline — Visual Explanation

Explore each step of the Retrieval-Augmented Generation pipeline interactively.


Select a view:

- ☐ ETL Overview ☐ Embedding Space ☒ RAG Pipeline ☐ Full Flow

🔄 RAG Pipeline Steps

From user question to grounded answer with citations.

🔄 RAG Pipeline Steps



📋 Step Breakdown

Docs Chunks
7 784

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Upload & Index a New Document

Upload a document (TXT, MD, CSV, or PDF) to ingest it through the ETL pipeline. The system will:

- Store raw content in **Bronze**
- Clean and chunk in **Silver**
- Embed and index in **Gold**

Choose a file (TXT/MD/CSV/PDF)



Drag and drop file here

Limit 200MB per file • TXT, MD, CSV, PDF

Browse files



-Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md 27.3KB



Selected: -Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md (27258 bytes)



Upload & Ingest Through Pipeline



Running ETL pipeline...

Gold: 110/865 مقطعا / chunks...

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Upload & Index a New Document

Upload a document (TXT, MD, CSV, or PDF) to ingest it through the ETL pipeline. The system will:

- Store raw content in **Bronze**
- Clean and chunk in **Silver**
- Embed and index in **Gold**

Choose a file (TXT/MD/CSV/PDF)



Drag and drop file here

Limit 200MB per file • TXT, MD, CSV, PDF

Browse files



-Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md 27.3KB



Selected: -Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md (27258 bytes)



Upload & Ingest Through Pipeline



Success! Document indexed

- Document: -Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md
- Chunks created: 865
- Indexed in Gold layer

View it in the Documents tab.

Indexed Documents

 8 Document(s) Indexed

Document	Chunks	Avg Size
-Global-Data-Privacy-Program-BRD-SDD-v1_3.md	165	~500 chars
-Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md	81	~500 chars
AEGIS_AI_ConceptPaper.pdf	197	~500 chars
AEGIS_AI_Presentation.pdf	22	~500 chars
Egypt-PDPL-self-assessment-v2_14.pdf	290	~500 chars
Introduction to Quantum mechanics.pdf	107	~500 chars
etl_notes.txt	1	~500 chars
rag_basics.md	2	~500 chars

Inspect Chunks

Select a document:

-Global-Data-Privacy-Program-BRD-SDD-v1_3.md

165 chunks from -Global-Data-Privacy-Program-BRD-SDD-v1_3.md

📍 Chunk #0 — 0d7f13bc-1c8...

Length

364 chars

ID: 0d7f13bc-1c8c-429e-9..

L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

Docs

8

Chunks

865

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Inspect Chunks

Select a document:

rag_basics.md

2 chunks from rag_basics.md

Chunk #0 — 2da02d7f-ae...

RAG Basics

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM. Instead of relying only on what the model memorized during training, RAG fetches relevant documents from a vector index and injects them into the prompt.

Chunking

Recursive chunking is the recommended default: split by paragraphs first, then split any oversized chunk by sentences. Aim for 300-800 characters with 10-20% overlap.

Evaluation

Chunk #1 — cc03aa26-ca9...

0 characters with 10-20% overlap.

Evaluation

The RAG triad measures faithfulness, answer relevancy, and context precision. The RAGAS framework implements these metrics.

Length

449 chars

ID: 2da02d7f-aeed-47f4-a...

Length

173 chars

ID: cc03aa26-ca98-4988-9...

L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

Docs 8 Chunks 865

Pipeline Config

Generator: openrouter
Model: nemotron-3-super-120
Embedding: all-MiniLM-L6-v2 (384-dim)
Index: HNSW Cosine
Cache Entries: 0

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)


Deploy

Step 1: Retrieval — Finding relevant chunks...

Retrieved 2 chunks

Retrieval Similarity Scores

Retrieval Similarity Scores



Step 2: Generation — Creating grounded answer...

Answer generated

Answer

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM, fetching relevant documents from a vector index and injecting them into the prompt to supplement the model’s knowledge. [2]

From semantic cache (92%+ similarity)

Retrieved Sources

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

📁 Docs

8

📊 Chunks

865

🛠️ Pipeline Config

Generator: [openrouter](#)

Model: [nemotron-3-super-120](#)

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 1

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🎯 Answer

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM. [2]

📄 From semantic cache (92%+ similarity)

📖 Retrieved Sources

[1] from [rag_basics.md](#)

Similarity

0.559

View chunk text

0 characters with 10-20% overlap.

Evaluation

The RAG triad measures faithfulness, answer relevancy, and context precision. The RAGAS framework implements these metrics.

[2] from [rag_basics.md](#)

Similarity

0.467

View chunk text

RAG Basics

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM. Instead of relying only on what the model memorized during training, RAG fetches relevant documents from a vector index and injects them into the prompt.

Chunking

Recursive chunking is the recommended default: split by paragraphs first, then split any oversized chunk by sentences. Aim for 300-800 characters with 10-20% overlap.

Evaluation

Docs

8

Chunks

865

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 1

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Evaluation Against Golden Dataset

Benchmark your RAG system against 12 reference questions.

Metrics:

- Context Precision ≈ average similarity of retrieved chunks
- Expected Source Found = whether the benchmark’s expected source appeared in results

Golden Dataset:

- 12 bilingual Q&A pairs
- AR/EN questions and references
- Expected source document name

Run Evaluation

Results

#	سؤال / Question	Precision	Source Found
1	ما الفرق بين ETL وELT...	0.3	✗
2	ما طبقات المعمارية المتدرّجة Medallion...	0.47	✓
3	ما مكونات عقد البيانات الثلاثة...	0.47	✗
4	ما الاستراتيجيات الموصى بها افتراضياً لتق...	0.36	✓
5	لماذا نستخدم البحث الهجين في الاسترجاع...	0.34	✗
6	ما وظيفة إعادة الترتيب Cross-encoder...	0.34	✗
7	ما مكونات مثلث تقييم RAG الثلاثة...	0.42	✓
8	كيف يقلل التخزين الدلالي المؤقت التكلفة...	0.23	✗
9	ما الفرق بين Agentic AI و AI Agent...	0.46	✗
10	ما طبقات المعمارية المرجعية للذكاء التول...	0.48	✗
			✗

Glossary

Glossary Map خريطة المصطلحات

البيانات والتخزين
Data & storage

الخصائص
Features

RAG والاسترجاع
RAG & retrieval

تعلم المصطلحات كمجموعات مترابطة
Learn terms as connected groups

الحوكمة
Governance

MLOps
MLOps

Data Pipeline	خط مسارات البيانات
ETL Extract, Transform, Load	الاستخراج والتحويل والتحميل
ELT	الاستخراج والتحميل والتحويل
Medallion Architecture	المعمارية المتدرّجة
Data Warehouse	مستودع البيانات
Data Lake	بحيرة البيانات

Glossary2

المصطلحات

Lakehouse

معمارية بحيرة البيانات الموحدة

Data Mesh

شبكة البيانات

Data Product

منتج البيانات

Data Contract

عقد البيانات

Data Lineage

سلسلة العهدة

Data Catalog

فهرس البيانات الكتالوج

Feature Engineering	هندسة الخصائص
Feature Store	مخزن الخصائص
Feature Skew	انحراف الميزات
Vector Database	قاعدة البيانات المتجهية
Embedding	التمثيل المتجهي
ANN Approximate Nearest Neighbor	البحث التقريبي لأقرب الجيران

HNSW Index	HNSW فهرس
Recursive Chunking	التقسيم التكراري
Semantic Chunking	التقسيم الدلالي
Hybrid Search	البحث الهجين
Dense Sparse Retrieval	البحث الكثيف المتناثر
Reranking	إعادة الترتيب

Grounded Prompting	الموجّه المقيّد بالمصادر
RAG Retrieval-Augmented Generation	التوليد المعزّز بالاسترجاع
Agentic RAG	RAG الوكيل
Faithfulness	الوفاء بالمصدر
Answer Relevancy	ملاءمة الإجابة
Context Precision	دقة السياق

Semantic Caching	التخزين الدلالي المؤقت
Single ChromaDB client no SQLite lock	عميل ChromaDB واحد لا قفل SQLite
Drop & recreate collection	حذف المجموعة وإعادة إنشائها
Batched encoding 10	الترميز بدفعات 10
Model Routing	توجيه الطلبات بين النماذج
LLM-assisted Labeling	التصنيف بمساعدة النموذج اللغوي

Human-in-the-loop	التحقق البشري
AI Gateway	بوابة الذكاء الاصطناعي
Prompt Library	مكتبة الموجّهات
Guardrails	حواجز الحماية
Responsible AI	الذكاء الاصطناعي المسؤول
FinOps	إدارة التكاليف السحابية

Experiment Tracking

تتبع التجارب

Data Versioning

إصدارات البيانات