

Module 02: Data Engineering for AI


وحدة 02: هندسة البيانات للذكاء الاصطناعي

7 Modules + Lab + Glossary

Interactive Learning Journey

وحدات المقرر Course Modules


- V06 أساسيات البيانات Data Fundamentals
- V07 المستودعات والبحيرات ومعمارية Lakehouse Warehouses, Data Lakes & Lakehouse
- V08 هندسة الخصائص ومخازنها Feature Engineering & Feature Stores
- V09 قواعد البيانات المتجهية RAG + التطبيقي Vector Databases + Applied RAG
- V10 تصنيف البيانات على نطاق واسع Labeling at Scale
- V11 حوكمة البيانات وسلسلة العهدة والفهرسة Data Governance, Lineage & Cataloging
- V12 أساسيات MLOps + تمهيد للمختبر MLOps Fundamentals + Lab Introduction



V06 — Data Fundamentals

Unified Data/AI Platform

تقنيات معالجة منصة البيانات الموحدة و الذكاء الاصطناعي



Unified Data/AI Platform

تقنيات معالجة منصة البيانات الموحدة و الذكاء الاصطناعي

Data Analysis and Segmentation

- جمع البيانات الأولية ، من خلال معالجة الأنشطة ، و التعرف على البيانات ، وتحديد جودة البيانات ، واكتشاف السمات الداخلية للبيانات مع اكتشاف المجموعة الفرعية المثيرة للاهتمام لتشكيل فرضية المعلومات الضمنية.
- إنشاء منظومة البيانات الموحدة من البيانات غير المعالجة و تشمل اختيار الجداول والسجلات والخواص ، بالإضافة إلى تحويل وتنظيف البيانات لأدوات النمذجة.

Predictive Forecasting Models

- استخدام تقنيات الذكاء الاصطناعي في اختيار تقنيات نماذج مختلفة وتطبيقها ، وتعديل معلمات النموذج إلى أفضل القيم. بشكل عام ، بما يساعد علي إيجاد حلول فعالة لمشكلة التنقيب في البيانات .
- تحليل السلاسل الزمنية و التنبؤ بالقيمة المستقبلية للسلسلة باستخدام المتوسطات المتحركة لتحليل السلاسل الزمنية إلى مكونات موسمية واتجاهية وغير منتظمة. التعامل مع المكونات الموسمية المضافة أو المضاعفة.

Anomaly & Fraud Detection


- اعداد القواعد المعرفية في النظم الخيرة هي مزيج من الخصائص والقوانين ونتائج الخبرة المكتسبة والمعلومات الدقيقة والادراك
- استخدام برامج الذكاء الاصطناعي للوصول إلى استنباط الظواهر و الأنماط الغير الطبيعية في البيانات (و احتمال مخالفتها للقوانين و المحددات) من خلال المسارات داخل قاعدة المعرفة

Decision Optimization & What-If-Scenarios

- حل المشاكل الجديدة، والتخطيط، واتخاذ القرارات والقدرة على التعامل مع المشاكل غير المتوقعة واستخلاص النتائج باستخدام المعلومات المخزنة
- محاكاة النتائج المستقبلية و الوصول الي افضل البدائل لتعظيم العائد من المشروع

Unified Data/AI Platform

تقنيات معالجة منصة البيانات الموحدة و الذكاء الاصطناعي



طيف البيانات والتنسيقات Data Spectrum & Formats

مهيكلية

Structured

شبه مهيكلية

Semi-structured

غير مهيكلية

Unstructured

جداول Tables

CSV Databases

سجلات مرنة Flexible records

JSON Avro

نصوص وصور وصوت Text,
images, audio

PDF JPG MP3

اختر التنسيق حسب الاستخدام: تبادلي بسيط ← تحليلات سريعة ← محتوى غني

Choose the format for the job: simple exchange ← fast analytics ← rich content

Parquet عمودي للتحليلات؛ JSON مرنة للواجهات؛ الملفات الغنية تحتاج استخراج محتوى.

Parquet is columnar for analytics; JSON is flexible for APIs; rich files need content extraction.

ETL: التحويل قبل التحميل؛ ELT: التحميل أولاً ثم التحويل داخل المنصة المستهدفة.

ETL: transform before loading; ELT: load first, transform inside the target platform.

ELT هو النمط السائد في بيئات Lakehouse الحديثة.

ELT is the dominant pattern in modern lakehouse environments.

مقارنة أنماط المعالجة Processing Patterns

المعمارية المتدرّجة: Medallion (Lakehouse)

Bronze خام Silver → منقّى Gold → جاهز للتحليل؛ إدارة مركزية؛ الأنسب للتحليلات وخطوط AI ML RAG.

Medallion (Lakehouse): raw Bronze → cleansed Silver → analytics-ready Gold; central ownership; best for analytics and AI ML RAG pipelines.

مستودع البيانات → Staging → ETL ELT: المستودع → أسواق البيانات؛ حوكمة مركزية؛ الأنسب للتقارير وذكاء الأعمال.

Data warehouse: ETL ELT → staging → warehouse → data marts; central governance; best for reporting and BI.

شبكة البيانات Data Mesh: ملكية لامركزية بالمجالات؛ منتجات بيانات بعقود) مخطط، أمان (SLA، وكتالوج موحد؛ الأنسب للمؤسسات الكبيرة.

Data mesh: decentralized domain ownership; data products with contracts (schema, security, SLA) and a unified catalog; best for large organizations.

جدول المقارنة Medallion: المستودع Data Mesh

المعيار	Medallion	المستودع	Data Mesh
الفكرة	طبقات Bronze→Silver→Gold	Staging→Warehouse →Marts	منتجات بالمجالات
المالك	هندسة مركزية	فرق BI	فرق المجالات
الأنسب	تحليلات و AI RAG	تقارير BI	مؤسسات كبيرة
الحوكمة	جودة بين الطبقات	مركزية	موحدة + عقود

اختبار قصير Quick Quiz

1. ما الفرق الجوهرى بين ETL و ELT؟

What is the key difference between ETL and ELT?

2. أين تُستخدم طبقة Gold في المعمارية المتدرّجة؟

Where is the Gold layer used in the Medallion architecture?

3. أي نمط يناسب مؤسسة كبيرة بفرق مستقلة وملكية لامركزية؟

Which pattern suits a large organization with independent, decentralized teams?

4. ما التنسيق الأنسب للتحليلات عالية الأداء ولماذا؟

Which format suits high-performance analytics and why?

إجابات الاختبار Quiz Answers

1. ETL يحوّل قبل التحميل؛ ELT يحمّل أولاً ثم يحوّل داخل المنصة الهدف.

ETL transforms before loading; ELT loads first and transforms inside the target platform.

2. تجميعات على مستوى الأعمال جاهزة للتحليل.

Business-level aggregates that are analytics-ready.

3. شبكة البيانات. Data Mesh.

Data mesh.

4. Parquet — تنسيق عمودي يقلل الحجم ويسرّع القراءة.

Parquet — columnar, smaller and faster for analytical reads.

V07 — Warehouses, Data Lakes & Lakehouse

أجندة العرض Agenda

— V07 المستودعات والبحيرات ومعمارية Lakehouse

V07 — Warehouses, Data Lakes & Lakehouse

المستودع مقابل البحيرة Warehouse vs Lake

معمارية Lakehouse Lakehouse

منتجات البيانات وعقودها Data Products & Contracts


متى تختار كل نموذج؟ When to Choose Which

المستودع مقابل البحيرة Warehouse vs Lake Decision Map


Data Warehouse



Data Lake



Data Lakehouse



خريطة قرار: المستودع مقابل البحيرة Warehouse vs Lake Decision Map

مستودع البيانات

Data Warehouse

مخطط عند الكتابة

Schema on write

+ بيانات منظمة SQL

Curated data + SQL

تقارير وذكاء أعمال

Reporting and BI

بحيرة البيانات

Data Lake

مخطط عند القراءة

Schema on read

كل التنسيقات

Any format

استكشاف و AI ML

Exploration and AI ML


Lakehouse = مرونة البحيرة + موثوقية المستودع

Lakehouse = lake flexibility + warehouse reliability


لا يوجد فائز دائم: ابدأ من نوع السؤال، والفريق، ومتطلبات الحوكمة.

There is no universal winner: start with the question, team, and governance needs.

Medallion Medallion Layers المعمارية المتدرّجة




المعمارية المتدرّجة Medallion Layers Medallion



الحوكمة عبر تحسين الجودة بين الطبقات — إدارة مركزية.

Governance via quality improvement between layers — central ownership.

منتج البيانات وعقد البيانات Data Product & Contract



وحدة التسليم الحديثة في هندسة البيانات.

The modern delivery unit in data engineering.

متى تختار كل نموذج؟ Decision Matrix

السبب	الاختيار	الحالة
مرونة + حوكمة طبقية	Medallion Lakehouse	فريق مركزي + تحليلات
SQL سريع + مخطط ثابت	Warehouse	تقارير صارمة
ملكية لامركزية + عقود	Data Mesh	فرق مستقلة كبيرة

Three Data Patterns أنماط معالجة البيانات الثلاثة

المعمارية المتدرّجة

Medallion

مستودع البيانات

Data Warehouse

شبكة البيانات

Data Mesh

فريق مركزي — تحليلات و AI ML
RAG

فرق — BI تقارير وذكاء أعمال

فرق المجالات — مؤسسات كبيرة

المعايير: الفكرة الجوهرية المالك الحوكمة حالة الاستخدام المثلى.

Criteria: core idea ownership governance best use case.

اختبار قصير Quick Quiz

1. ما معنى «مخطط عند القراءة»؟

What does 'schema-on-read' mean?

2. ما مكونات عقد البيانات الثلاثة؟

What are the three components of a data contract?

3. ماذا يضيف Lakehouse عن البحيرة المجردة؟

What does a lakehouse add over a raw lake?

Quiz Answers إجابات الاختبار

1. لا يُفرض المخطط عند الكتابة بل عند القراءة — سمة البحيرات.

Schema is enforced at read time, not write time — a lake trait.

2. المخطط، الأمان، مستوى الخدمة. SLA.

Schema, security, and SLA.

3. معاملات ACID وأداء SQL وحوكمة.

ACID transactions, SQL performance, and governance.

V08 — Feature Engineering & Feature Stores

أجندة العرض Agenda

— V08 هندسة الخصائص ومخازنها

V08 — Feature Engineering & Feature Stores


هندسة الخصائص Feature Engineering

مخازن الخصائص Feature Stores

اتساق Consistency Offline Online

الربط بالتطبيقات الوكيله Agentic Applications


من البيانات الخام إلى الخصائص Raw Data to Features



الاتساق هو النتيجة: نفس حساب الميزة يمنع انحراف التدريب والخدمة.

Consistency is the outcome: the same feature calculation prevents training-serving skew.

معمارية مخزن الخصائص Feature Store Architecture



الربط بالتطبيقات الوكيلية Agentic Applications


الوكلاء يحتاجون ميزات لحظية متسقة لقرارات التخصيص والمخاطر والتوجيه.

Agents need consistent real-time features for personalization, risk, and routing.


مخزن الخصائص هو «مصدر الحقيقة» للميزات أمام أي وكيل ذكي.

The feature store is the single source of truth behind any agent.

RAG



Agentic RAG



اختبار قصير Quick Quiz

1. ما المشكلة التي يحلها مخزن الخصائص؟

What problem does a feature store solve?

2. فرّق بين المخزن Offline وOnline.

Differentiate offline vs online stores.

3. اذكر أداتين لمخازن الخصائص.

Name two feature-store tools.

إجابات الاختبار Quiz Answers

1. انحراف الميزات بين التدريب والخدمة وتكرار العمل.

Feature skew between training serving and duplicated work.

2. Offline للتدريب التاريخي؛ Online لخدمة فورية منخفضة الكمون.

Offline for historical training; online for low-latency serving.

3. Feast و Hopsworks أو Tecton).

Feast and Hopsworks (or Tecton).

V09 — Vector Databases + Applied RAG

أجندة العرض Agenda

— V09 قواعد البيانات المتجهية RAG + التطبيقي

V09 — Vector Databases + Applied RAG

قواعد البيانات المتجهية Vector Databases

1) الفهرسة: استراتيجيات التقسيم Indexing: Chunking


2) الاسترجاع Retrieval

3) التوليد Generation

4) التقييم (5 +) التحسين Evaluation + Optimization

الأخطاء الشائعة Common Pitfalls

خط مسارات RAG Pipeline



استراتيجيات تقسيم النصوص Chunking Strategies

ثابت الحجم Fixed-size	أبسطها — يقطع الجُمْل
دلالي Semantic	تماسك أفضل — حساس للعتبة
تكراري ★ Recursive	الموصى به افتراضياً
بحسب البنية Structure-based	عناوين وأقسام — يُدمج مع التكراري
بالنموذج اللغوي LLM-based	الأدق — الأعلى حسابياً

★ التقسيم التكراري: فصل بالفقرات ثم تقسيم ما تجاوز الحد الأقصى.

★ Recursive: split by paragraphs, then oversized chunks.

2) الاسترجاع. Retrieval.

بحث هجين: كثيف + (Dense) متناثر (BM25) يغطي المعنى والكلمات المفتاحية معًا.

Hybrid search: dense + sparse (BM25) covers meaning and keywords.

إعادة ترتيب Cross-encoder وتحويل الاستعلام Multi-Query يرفعان دقة النتائج.


Cross-encoder reranking and multi-query transformation improve precision.

3) التوليد Generation

موجّه مقيد بالمصادر المسترجعة (Grounded Prompting) مع الاستشهاد: «أجب فقط من السياق المرفق.»

Grounded prompting strictly on retrieved sources with citations: 'answer only from the provided context'.

نمط الإجابة المؤرّضة Grounded Answer Pattern



القاعدة: لا تتجاوز الأدلة، واربط كل ادعاء بمصدر.

Rule: do not go beyond the evidence; connect every claim to a source.

4التقييم + 5 التحسين Evaluation + Optimization


مثلث RAG: الوفاء (Faithfulness)، ملاءمة الإجابة (Answer Relevancy)، دقة السياق (Context Precision) —
RAGAS. بإطار

RAG triad: faithfulness, answer relevancy, context precision — measured with RAGAS.

التحسين: تخزين دلالي مؤقت، توجيه الطلبات بين النماذج، ومراقبة مستمرة.

Optimization: semantic caching, model routing, continuous monitoring.

RAG Evaluation Triad مثلث تقييم



يُقاس بإطار RAGAS — الوفاء يمنع الهلوسة والملاءمة تجعل الإجابة نافعة.

Measured with RAGAS — faithfulness prevents hallucination; relevancy keeps answers useful.



Common Pitfalls الأخطاء الشائعة

تقسيم يكسر الجداول أو الأكواد؛ إهمال إعادة الترتيب فيضيع الأكثر ملاءمة.

Chunking that breaks tables code; skipping reranking loses the most relevant hits.

غياب تقييم الوفاء فيسمح بالهلوسة؛ استرجاع أعلى-ك دون حد أدنى للدرجة.

No faithfulness evaluation allows hallucination; top-k without a score floor.

 Indexing Chunking Strategy (Recursive), Embedding Model (Domain-aligned), Vector Index (HNSW).	 Retrieval Hybrid Search (Dense+Sparse), Reranking (Cross-encoder), Query Transformation (Multi-Query).	 Generation Grounded Prompting (Strict Instructions), Source Citations.
	 Evaluation The RAG Triad (Faithfulness, Answer Relevancy, Context Precision).	
	 Optimization Semantic Caching, Model Routing, Continuous Monitoring.	

اختبار قصير Quick Quiz

1. ما استراتيجية التقسيم الموصى بها افتراضياً؟

Which chunking strategy is the recommended default?

2. لماذا نجمع البحث الكثيف مع BM25؟

Why combine dense search with BM25?

3. ما مكونات مثلث تقييم RAG الثلاثة؟

Name the three parts of the RAG evaluation triad.

4. ما وظيفة إعادة الترتيب Cross-encoder؟

What does cross-encoder reranking do?

5. كيف يقلل التخزين الدلالي المؤقت التكلفة؟

How does semantic caching cut cost?

إجابات الاختبار Quiz Answers

1. التقسيم التكراري. Recursive Chunking.

Recursive chunking.

2. الكثيف يفهم المعنى و BM25 يطابق الكلمات النادرة حرفيًا.

Dense captures meaning; BM25 matches rare exact keywords.

3. الوفاء، ملاءمة الإجابة، دقة السياق.

Faithfulness, answer relevancy, context precision.

4. يعيد ترتيب المرشحين بنموذج أدق لرفع ملاءمة النتائج.

Re-scores candidates with a more accurate model.

5. يعيد استخدام إجابات الأسئلة المشابهة بدل استدعاء النموذج كل مرة.

Reuses answers for similar questions.

V10 — Labeling at Scale

أجندة العرض Agenda

— V10 تصنيف البيانات على نطاق واسع


V10 — Labeling at Scale

لماذا التصنيف؟؟ Why Labeling

الأدوات Tools

LLM التصنيف بمساعدة LLM-assisted Labeling

حلقة جودة التصنيف Label Quality Loop



الـ LLM يسرّع العمل؛ الإنسان يظل مسؤولاً عن القبول والجودة.

The LLM accelerates work; people remain accountable for acceptance and quality.

Label Studio للتعددية Roboflow، للرؤية الحاسوبية Scale AI، للتوسع المؤسسي.

Label Studio for versatility, Roboflow for vision, Scale AI for enterprise scale.

LLM-assisted Labeling LLM التصنيف بمساعدة


نموذج لغوي يقترح التصنيفات مبدئيًا لتسريع العملية وخفض التكلفة.

An LLM pre-labels examples to speed up the process and cut cost.

التحقق البشري (Human-in-the-loop) إلزامي قبل القبول، مع قياس اتفاق النموذج مع البشر.

Human-in-the-loop validation is mandatory before acceptance, measuring human-model agreement.

سير عمل التصنيف بمساعدة LLM LLM-assisted Labeling Workflow



الـ LLM يسرّع التسمية والبشر يضمنون الجودة — أفضل الممارسات الحديثة.

LLM accelerates labeling; humans guarantee quality — modern best practice.

اختبار قصير Quick Quiz

1. لماذا لا نعتمد تصنيفات LLM مباشرة دون مراجعة؟

Why not accept LLM labels directly without review?

2. أي أداة تناسب مشاريع الرؤية الحاسوبية؟

Which tool fits computer-vision projects?

إجابات الاختبار Quiz Answers

1. لأن النموذج قد يخطئ أو يتحيز — التحقق البشري يضمن الجودة.

The model can err or be biased — human validation guarantees quality.

2. Roboflow.

Roboflow.

V11 — Data Governance, Lineage & Cataloging

أجندة العرض Agenda

— V11 حوكمة البيانات وسلسلة العهدة والفهرسة

V11 — Data Governance, Lineage & Cataloging

الحوكمة والفهرسة Governance & Cataloging

المعمارية المرجعية للذكاء التوليدي (2 1)(1 2) GenAI Reference Architecture

المعمارية المرجعية للذكاء التوليدي (2 2)(2 2) GenAI Reference Architecture

الحوكمة والفهرسة Governance & Cataloging


سلسلة العهدة (Lineage) تتبع أصل البيانات وتحولاتها؛ الفهرسة تجعلها قابلة للاكتشاف.

Lineage traces data origin and transformations; cataloging makes it discoverable.

أدوات. : Apache Atlas، Collibra، DataHub, OpenMetaData.

Tools: Apache Atlas, Collibra, DataHub, OpenMetaData

خريطة سلسلة العهدة Data Lineage Map



اسأل «من أين جاءت هذه النتيجة؟» ثم اتبع السلسلة إلى المصدر.

Ask “where did this result come from?” then follow the chain to its source.

المعمارية المرجعية للذكاء التوليدي (1 2) GenAI Reference Architecture

أ. بوابة منصة GenAI: نافذة موحدة بكتالوج حلول ومحفظة POC → MVP → PROD موثقة.

A. Portal: unified pane of glass with a solution catalog and documented POC → MVP → PROD portfolio.

ب. الأتمتة والامتثال: خطوط CI CD ببوابات تحكم آلية وموافقات مرحلية وفق DevSecOps.

B. Automation & compliance: CI CD with automated control gates and stage-gate approvals (DevSecOps).

المعمارية المرجعية للذكاء التوليدي (2 2) GenAI Reference Architecture

ج. الخدمات المشتركة: بوابة AI موحدة، مكتبة موجّهات، خدمة التغذية الراجعة، قاعدة تدقيق LLM، حواجز حماية. Guardrails.

C. Shared services: unified AI gateway, prompt library, feedback service, LLM audit database, guardrails.

د. الحوكمة والمراقبة: أمن البيانات، الذكاء المسؤول (تدقيق التحيز والهلوسة)، وإدارة التكاليف. FinOps.

D. Governance & monitoring: data security, responsible AI (bias hallucination audits), FinOps.

المعمارية المرجعية للذكاء التوليدي GenAI Reference Architecture

أ. بوابة منصة GenAI

A. Platform Portal — POC → MVP → PROD

ب. الأتمتة والامتثال

B. Automation & Compliance — CI CD gates

ج. الخدمات المشتركة

C. Shared Services — Gateway, Prompts, Audit, Guardrails

د. الحوكمة والمراقبة

D. Governance & Monitoring — Responsible AI, FinOps

النمط المرجعي المؤسسي — (McKinsey) نافذة موحدة فوق خدمات مشتركة محكومة.

Enterprise reference pattern (McKinsey) — a unified pane over governed shared services.

اختبار قصير Quick Quiz

1. ما وظيفة بوابة AI الموحدة (AI Gateway) ؟

What does a unified AI gateway do?

2. لماذا نحتاج قاعدة تدقيق لنماذج LLM ؟

Why keep an LLM audit database?

3. ما دور CI CD في حوكمة GenAI ؟

What is CI CD's role in GenAI governance?

إجابات الاختبار Quiz Answers

1. نقطة دخول موحدة تفرض المصادقة والحدود والتسجيل على كل الاستدعاءات.

A single entry point enforcing auth, limits, and logging for all calls.

2. لتتبع الموجّهات والإجابات والامتثال والتحقيق في الحوادث.

To trace prompts answers for compliance and investigation.

3. بوابات تحكم وموافقات مرحلية آلية قبل الإنتاج.

Automated control gates and approvals before production.

V12 — MLOps Fundamentals + Lab Introduction

أجندة العرض Agenda

— V12 أساسيات + MLOps تمهيد للمختبر

V12 — MLOps Fundamentals + Lab Introduction


MLOps والأدوات MLOps & Tools

تميز المفاهيم Concept Distinctions

RAG الوكيل Agentic RAG

التكلفة والأداء عملياً Practical Cost & Performance

تمهيد للمختبر Lab Introduction L03



MLOps دورة حياة MLOps Lifecycle

MLflow لتتبع التجارب والنماذج Kubeflow، لأتمتة الخطوط DVC، لإصدارات البيانات.

MLflow for tracking, Kubeflow for pipeline automation, DVC for data versioning.



سجل الإصدارات والقياسات في كل مرحلة — ثم أعد التعلم من الإنتاج
Record versions and metrics at every stage — then learn again from production

MLOps ليس «نشرًا مرة واحدة»؛ إنه حلقة قابلة للقياس والتحسين.

MLOps is not “deploy once”; it is a measurable improvement loop.

تميز المفاهيم Concept Distinctions


LLM: يرمز النص ويتنبأ بالرموز التالية. الذكاء التوليدي: يولد محتوى جديداً (نص صورة صوت).

LLM: predicts next tokens. Generative AI: generates new content (text image audio).

الوكلاء: يكشفون النية ويستدعون الأدوات. الأنظمة الوكيلية: تخطيط ذاتي وتنفيذ متعدد الخطوات مع تقييم للنتائج.

Agents: detect intent and call tools. Agentic AI: self-directed multi-step planning with outcome evaluation.

من LLM إلى الأنظمة الوكيلية LLM to Agentic AI



Agentic RAG = بحث متجهي + جلب عبر الواجهات بذاكرة متجددة وتحقق قبل التسليم.

Agentic RAG = vector search + API fetching with refreshed memory and verification.

Agentic RAG الوكيل

يجمع البحث المتجهي وجلب البيانات عبر الواجهات في عملية متعددة الخطوات، بذاكرة محدّثة وتحقق من النتائج قبل التسليم.

Combines vector search and API fetching in multi-step flows, with refreshed memory and verification before delivery.

التكلفة والأداء عمليًا Practical Cost & Performance

التضمين (Embedding) أقل تكلفة بمرتبة كاملة من التوليد — (Generation) الاسترجاع أرخص من التوليد.

Embedding costs an order of magnitude less than generation — retrieval is cheaper than generation.


التخزين الدلالي المؤقت يخفض الكمون والتكلفة؛ توجيه الطلبات يرسل المهام البسيطة لنماذج أصغر أرخص.

Semantic caching cuts latency and cost; routing sends easy tasks to smaller, cheaper models.

قاعدة FinOps: قس التكلفة لكل طلب (per-request) قبل التوسع.

FinOps rule: measure per-request cost before scaling.

التكلفة عمليًا: التضمين مقابل التوليد Cost: Embedding vs Generation



قاعدة FinOps: قس التكلفة لكل طلب قبل التوسع.

FinOps rule: measure per-request cost before scaling.

معمارية مختبر L03 L03 Lab Architecture

خط ETL (etl_pipeline.py): SQLite Bronze (etl_pipeline.py) ← تنظيف + تقسيم 500 50 Gold ← (ChromaDB HNSW cosine) دفعات 10
ETL (etl_pipeline.py): Bronze (raw SQLite) → Silver (clean + 500 50 chunk) → Gold (ChromaDB HNSW cosine, batches of 10)

الخلفية: (rag_api.py:8000) استرجاع كثيف top-k=5 حد 0.2 ← توليد مؤرّض ← OpenRouter free كاش دلالي 0.92 ← تقييم 12 golden سؤالاً
Backend (rag_api.py:8000): dense top-k=5 ≥0.2 → grounded OpenRouter free → semantic cache 0.92 → golden eval (12 Q)

الواجهة: (streamlit_ui.py:8501) 5 تبويبات ثنائية — رفع مستندات استعلام تقييم حول — تُعيد استخدام نفس عميل Chroma مع حذف المجموعة وإعادة إنشائها
Frontend (streamlit_ui.py:8501): 5 bilingual tabs — upload docs query eval about — same Chroma client, drop & recreate

المخازن l03_lab.db (bronze_docs silver_chunks + chroma_db (gold_chunks + env.) 384 بعد golden_dataset.json + المفتاح
Stores: l03_lab.db (bronze_docs silver_chunks) + chroma_db (gold_chunks dim 384) + golden_dataset.json + .env for keys

L03 Running the L03 Lab **تشغيل مختبر**

```
cd l03_lab + source .venv bin activate
```

```
OMP_NUM_THREADS=1 MKL_NUM_THREADS=1 TOKENIZERS_PARALLELISM=false python -u etl_pipeline.py
```

```
.run_ui.sh → http: localhost:8501
```

```
uvicorn rag_api:app --reload → http: localhost:8000 docs
```

```
python rag_api.py evaluate
```

دائمًا من داخل الـ venv — التشغيل الخارجي يسبب segfault.
Always inside the venv — outside env segfaults.

اختبار قصير Quick Quiz

1. فرّق بين AI Agent و. Agentic AI

Differentiate an AI agent from agentic AI.

2. ما أرخص: تضمين أم توليد؟

Which is cheaper: embedding or generation?

3. ما أدوات تتبع التجارب وإصدارات البيانات؟

Which tools track experiments and version data?

إجابات الاختبار Quiz Answers

1. الوكيل يستجيب ويستدعي أدوات؛ الوكيل يخطط ذاتيًا وينفذ خطوات متعددة ويتكيف.

An agent responds and calls tools; agentic AI self-plans multi-step execution.

2. التضمين — أقل بتكلفة مرتبة كاملة.

Embedding — roughly an order of magnitude cheaper.

3. MLflow للتتبع و DVC لإصدارات البيانات.

MLflow for tracking, DVC for data versioning.

L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

 Docs

 Chunks

7

784

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

 Educational Flow

 Upload & Ingest

 Documents

 Query

 Evaluation

 About

RAG Pipeline — Visual Explanation

Explore each step of the Retrieval-Augmented Generation pipeline interactively.

Select a view:

- ☒ ETL Overview
- ☐ Embedding Space
- ☐ RAG Pipeline
- ☐ Full Flow

ETL Layers: Bronze → Silver → Gold

- Bronze** (): Raw documents stored unmodified in SQLite
- Silver** (): Documents cleaned, normalized, recursively chunked (500 chars, 50 overlap)
- Gold** (): Chunks embedded and indexed in ChromaDB with HNSW (cosine distance)

 Bronze

(Raw Documents)

 Silver

(Cleaned & Chunked)

 Gold

(Indexed Embeddings)

Documents

7

-

Chunks

0

Indexed Vectors

784

ETL Process Details

 Bronze Layer

^

What happens:

- Read TXT, MD, CSV, PDF files

 Silver Layer

^

What happens:

- Remove exact duplicates

 Gold Layer

^

What happens:

- Convert chunks to embeddings

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

📁 Docs

📊 Chunks

7

784

🔧 Pipeline Config

Generator: `openrouter`

Model: `nemotron-3-super-120`

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🎓 Educational Flow 📁 Upload & Ingest 📁 Documents 💬 Query 📊 Evaluation ⚙️ About

🎓 RAG Pipeline — Visual Explanation

Explore each step of the Retrieval-Augmented Generation pipeline interactively.


Select a view:

☐ ETL Overview ☒ Embedding Space ☐ RAG Pipeline ☐ Full Flow

📊 Chunk Embedding Visualization

See how chunks are positioned in embedding space. Similar chunks cluster together.

📊 Chunk Embedding Space (PCA Projection)



📌 784 chunks visualized in 2D space using PCA dimensionality reduction

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

 Docs

 Chunks

7

784

📦 Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🎓 RAG Pipeline — Visual Explanation

Explore each step of the Retrieval-Augmented Generation pipeline interactively.


Select a view:

- ☐ ETL Overview ☐ Embedding Space ☒ RAG Pipeline ☐ Full Flow

🔄 RAG Pipeline Steps

From user question to grounded answer with citations.

🔄 RAG Pipeline Steps



📋 Step Breakdown

Docs Chunks
7 784

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Upload & Index a New Document

Upload a document (TXT, MD, CSV, or PDF) to ingest it through the ETL pipeline. The system will:

- Store raw content in **Bronze**
- Clean and chunk in **Silver**
- Embed and index in **Gold**

Choose a file (TXT/MD/CSV/PDF)



Drag and drop file here

Limit 200MB per file • TXT, MD, CSV, PDF

Browse files



-Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md 27.3KB



Selected: -Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md (27258 bytes)



Upload & Ingest Through Pipeline



Running ETL pipeline...

Gold: 110/865 مقطعا / chunks...



- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Upload & Index a New Document

Upload a document (TXT, MD, CSV, or PDF) to ingest it through the ETL pipeline. The system will:

- Store raw content in **Bronze**
- Clean and chunk in **Silver**
- Embed and index in **Gold**

Choose a file (TXT/MD/CSV/PDF)



Drag and drop file here

Limit 200MB per file • TXT, MD, CSV, PDF

Browse files



-Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md 27.3KB



Selected: -Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md (27258 bytes)



Upload & Ingest Through Pipeline



Success! Document indexed

- Document: -Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md
- Chunks created: 865
- Indexed in Gold layer

View it in the Documents tab.

Deploy

L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

Docs

7

Chunks

784

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

Educational Resources:

[RAGAS Evaluation](#)

[ChromaDB Docs](#)

[RAG Fundamentals](#)

Educational Flow

Upload & Ingest

Documents

Query

Evaluation

About

Indexed Documents

8 Document(s) Indexed

Document	Chunks	Avg Size
-Global-Data-Privacy-Program-BRD-SDD-v1_3.md	165	~500 chars
-Trust-Layer-AI-Governance-Platform-BRD-SDD-v0_2.md	81	~500 chars
AEGIS_AI_ConceptPaper.pdf	197	~500 chars
AEGIS_AI_Presentation.pdf	22	~500 chars
Egypt-PDPL-self-assessment-v2_14.pdf	290	~500 chars
Introduction to Quantum mechanics.pdf	107	~500 chars
etl_notes.txt	1	~500 chars
rag_basics.md	2	~500 chars

Inspect Chunks

Select a document:

-Global-Data-Privacy-Program-BRD-SDD-v1_3.md

165 chunks from -Global-Data-Privacy-Program-BRD-SDD-v1_3.md

Chunk #0 — 0d7f13bc-1c8...

Global Data Privacy Program

Unified Privacy Principles (U.P.P.) 2020 - 2021

Length

364 chars

ID: 0d7f13bc-1c8c-429e-9...

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

📁 Docs

8

📊 Chunks

865

🛠 Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🔍 Inspect Chunks

Select a document:

rag_basics.md

📄 2 chunks from rag_basics.md

📌 Chunk #0 — 2da02d7f-ae...

RAG Basics

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM. Instead of relying only on what the model memorized during training, RAG fetches relevant documents from a vector index and injects them into the prompt.

Chunking

Recursive chunking is the recommended default: split by paragraphs first, then split any oversized chunk by sentences. Aim for 300-800 characters with 10-20% overlap.

Evaluation

📌 Chunk #1 — cc03aa26-ca9...

0 characters with 10-20% overlap.

Evaluation

The RAG triad measures faithfulness, answer relevancy, and context precision. The RAGAS framework implements these metrics.

Length

449 chars

ID: 2da02d7f-aeed-47f4-a...

Length

173 chars

ID: cc03aa26-ca98-4988-9...

L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

Docs8

Chunks865

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 0

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)


Deploy

📌 Step 1: Retrieval — Finding relevant chunks...

✅ Retrieved 2 chunks

Retrieval Similarity Scores

🔍 Retrieval Similarity Scores



🧠 Step 2: Generation — Creating grounded answer...

✅ Answer generated

🎯 Answer

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM, fetching relevant documents from a vector index and injecting them into the prompt to supplement the model’s knowledge. [2]

📄 From semantic cache (92%+ similarity)

📖 Retrieved Sources

🎓 L03 — RAG Lab

Educational Edition

Bronze → Silver → Gold → RAG Pipeline

محلي بالكامل / fully local, no Docker

📁 Docs

8

📊 Chunks

865

🛠️ Pipeline Config

Generator: `openrouter`

Model: `nemotron-3-super-120`

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 1

📚 Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

🎯 Answer

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM. [2]

📄 From semantic cache (92%+ similarity)

📖 Retrieved Sources

[1] from `rag_basics.md`

Similarity

0.559

View chunk text

0 characters with 10-20% overlap.

Evaluation

The RAG triad measures faithfulness, answer relevancy, and context precision. The RAGAS framework implements these metrics.

[2] from `rag_basics.md`

Similarity

0.467

View chunk text

RAG Basics

Retrieval-Augmented Generation (RAG) combines a retrieval step with a generative LLM. Instead of relying only on what the model memorized during training, RAG fetches relevant documents from a vector index and injects them into the prompt.

Chunking

Recursive chunking is the recommended default: split by paragraphs first, then split any oversized chunk by sentences. Aim for 300-800 characters with 10-20% overlap.

Evaluation

Docs

8

Chunks

865

Pipeline Config

Generator: openrouter

Model: nemotron-3-super-120

Embedding: all-MiniLM-L6-v2 (384-dim)

Index: HNSW Cosine

Cache Entries: 1

Educational Resources:

- [RAGAS Evaluation](#)
- [ChromaDB Docs](#)
- [RAG Fundamentals](#)

Evaluation Against Golden Dataset

Benchmark your RAG system against 12 reference questions.

Metrics:

- Context Precision ≈ average similarity of retrieved chunks
- Expected Source Found = whether the benchmark’s expected source appeared in results

Golden Dataset:

- 12 bilingual Q&A pairs
- AR/EN questions and references
- Expected source document name


Run Evaluation

Results

#	سؤال / Question	Precision	Source Found
1	ما الفرق بين ETL وELT...	0.3	✗
2	ما طبقات المعمارية المتدرّجة Medallion...	0.47	✓
3	ما مكونات عقد البيانات الثلاثة...	0.47	✗
4	ما الاستراتيجيات الموصى بها افتراضياً لتق...	0.36	✓
5	لماذا نستخدم البحث الهجين في الاسترجاع...	0.34	✗
6	ما وظيفة إعادة الترتيب Cross-encoder...	0.34	✗
7	ما مكونات مثلث تقييم RAG الثلاثة...	0.42	✓
8	كيف يقلل التخزين الدلالي المؤقت التكلفة...	0.23	✗
9	ما الفرق بين Agentic AI و AI Agent...	0.46	✗
10	ما طبقات المعمارية المرجعية للذكاء التول...	0.48	✗
			✗

Glossary

Glossary Mapخريطة المصطلحات



استخدم هذه الخريطة قبل الرجوع إلى التعريفات التفصيلية.

Use this map before returning to the detailed definitions.

المصطلحات (1) Glossary

Data Pipeline	خط مسارات البيانات
ETL (Extract, Transform, Load)	الاستخراج والتحويل والتحميل
ELT	الاستخراج والتحميل والتحويل
Medallion Architecture	المعمارية المتدرّجة
Data Warehouse	مستودع البيانات
Data Lake	بحيرة البيانات

Glossary(2) المصطلحات

Lakehouse	معمارية بحيرة البيانات الموحدة
Data Mesh	شبكة البيانات
Data Product	منتج البيانات
Data Contract	عقد البيانات
Data Lineage	سلسلة العهدة
Data Catalog	فهرس البيانات الكتالوج

Glossary(3) المصطلحات

Feature Engineering	هندسة الخصائص
Feature Store	مخزن الخصائص
Feature Skew	انحراف الميزات
Vector Database	قاعدة البيانات المتجهية
Embedding	التمثيل المتجهي
ANN (Approximate Nearest Neighbor)	البحث التقريبي لأقرب الجيران

Glossary(4) المصطلحات

HNSW Index	فهرسHNSW
Recursive Chunking	التقسيم التكراري
Semantic Chunking	التقسيم الدلالي
Hybrid Search	البحث الهجين
Dense Sparse Retrieval	البحث الكثيف المتناثر
Reranking	إعادة الترتيب

Glossary(5) المصطلحات

Grounded Prompting	الموجّه المقيّد بالمصادر
RAG (Retrieval-Augmented Generation)	التوليد المعزّز بالاسترجاع
Agentic RAG	RAG الوكيل
Faithfulness	الوفاء بالمصدر
Answer Relevancy	ملاءمة الإجابة
Context Precision	دقة السياق

المصطلحات (6) Glossary

Semantic Caching

التخزين الدلالي المؤقت

Single ChromaDB client (no SQLite lock)

عميل ChromaDB واحد لا قفل SQLite

Drop & recreate collection

حذف المجموعة وإعادة إنشائها

Batched encoding (10)

الترميز بدفعات (10)

Model Routing

توجيه الطلبات بين النماذج

LLM-assisted Labeling

التصنيف بمساعدة النموذج اللغوي

Glossary(7) المصطلحات

Human-in-the-loop	التحقق البشري
AI Gateway	بوابة الذكاء الاصطناعي
Prompt Library	مكتبة الموجّهات
Guardrails	حواجز الحماية
Responsible AI	الذكاء الاصطناعي المسؤول
FinOps	إدارة التكاليف السحابية

Glossary(8) المصطلحات

Experiment Tracking

تتبع التجارب

Data Versioning

إصدارات البيانات